

Profil

Étudiant en **Master Data & Intelligence Artificielle** à HETIC, je recherche une alternance à partir de **septembre 2026** (3 semaines entreprise / 1 semaine formation) en tant qu'**AI Engineer**. Expérience concrète en **conception et déploiement d'agents LLM en production** (Claude API Anthropic, modèles open-source, LangChain, function calling, streaming SSE), en **architecture RAG complète from scratch** (ingestion, chunking, embeddings, vector store, génération, évaluation) et en **industrialisation** (Docker, CI/CD, versioning, monitoring). Utilisateur quotidien de **Claude Code et Cursor** pour le développement. Vision claire : l'IA est un outil de construction logicielle avant d'être un sujet de recherche. Rigoureux, autonome, orienté impact concret.

Compétences

LLM & Agents IA

Claude API (Anthropic) production, **LangChain** (chaînes, retrievers, tools), **LangGraph** (agents stateful), Ollama / modèles open-source locaux (Llama 3, Mistral), **MCP (Model Context Protocol)**, PydanticAI, function calling / tool use, streaming SSE, prompt engineering avancé, guardrails

RAG & Recherche Sémantique

RAG from scratch, embeddings (HuggingFace / sentence-transformers), **ChromaDB**, FAISS, Qdrant (notions), Elasticsearch (full-text + vectoriel), chunking stratégique, reranking, évaluation (golden sets, hallucinations, pertinence)

Développement & APIs

Python (solide), **FastAPI** (REST API, auth JWT, webhooks, architecture modulaire), PostgreSQL, MongoDB, Redis, Pydantic, JavaScript / TypeScript, Vue.js 3, Node.js

MLOps & Industrialisation

Docker / Docker Compose, **CI/CD GitHub Actions** / **GitLab**, versioning (modèles, prompts, config), monitoring (logs, rate limiting, alerting), tests automatisés (Pytest), Git

Cloud & Data

GCP / BigQuery, AWS S3, Azure (initiation), Kafka, Spark, Airflow, Elasticsearch, SQL avancé

Outils IA quotidiens

Claude Code, **Cursor**, benchmarking de modèles et frameworks, veille active (arXiv, Anthropic, HuggingFace)

Langues

Français C2 Anglais B2

Expérience professionnelle

Développeur Web & AI – Visibl (Agence Web) – Paris, full remote

Juin – Août 2026

- ▷ Développement et livraison de sites web clients, DNS, paiement en ligne, déploiement.
- ▷ **Automatisation de réponses par mails.**
- ▷ Utilisation de **Claude (Anthropic)** comme assistant de développement et de génération de code.

AI Engineer – Projet industriel SKIPPER NDT (HETIC)

Févr. – Avr. 2026

Formation

Mastère Spécialisé en Data & IA

HETIC, Paris 2025–2026

- ▷ IA générative : LLMs, RAG, agents, NLP
- ▷ ML, Deep Learning, Computer Vision
- ▷ Cloud : GCP, AWS, Azure, Docker, Kubernetes
- ▷ Big Data : Spark, Kafka, Airflow

Master Systèmes d'Information Répartis

Université Cheikh Anta Diop (UCAD) 2024–2025

- ▷ Architectures distribuées, APIs REST
- ▷ ML, Big Data, bases de données

Licence Informatique

Université Cheikh Anta Diop (UCAD) 2021–2024

Centres d'intérêt

Agents IA & LLMs

GenAI engineering

Football

Boxe

Veille (Anthropic, arXiv)

- ▷ Conception et livraison d'un pipeline ML production-ready sur données industrielles réelles : de l'expérimentation (PyTorch) au déploiement documenté.
- ▷ Rigueur d'ingénierie : versioning du modèle, tests de robustesse, évaluation par métriques (Accuracy 93%, Recall 98%, MAE 0.82 m), documentation technique livrée au client.
- ▷ Méthodologie transposable : même approche d'itération et de validation appliquée à des systèmes IA plus larges (RAG, agents).

Data Analyst – Projet Grace & Mila (HETIC)

Déc. 2025

- ▷ BigQuery (GCP), SQL avancé (~4M users), KPIs, dashboards – restitution métier.

Projets

Plateforme RAG – Agent IA from Scratch (architecture RAG complète +  github.com/albarSamb/rag-assistant industrialisation)

- ▷ **RAG from scratch**: ingestion → chunking → embeddings (HuggingFace) → ChromaDB → génération **Claude API (Anthropic)**. Compréhension profonde de chaque couche.
- ▷ **Prompt engineering avancé** : instructions système, guardrails, évaluation des réponses (golden sets, hallucinations).
- ▷ **Industrialisation** : FastAPI, Docker, **CI/CD GitHub Actions**, tests Pytest, versioning des prompts.

Bichette Thomas : App web avec Agent LLM en production (bichet-  github.com/Birame-Owens/bichete-thomas tethomas.site)

- ▷ **Agent LLM en production réelle** : **Claude API**, function calling, contexte dynamique, historique multi-tour, streaming SSE – intégré dans un écosystème SaaS gestion de salon de coiffure (réservations, paiements Stripe, CRM).
- ▷ **Architecture AI First** : FastAPI + Vue.js 3 / TypeScript, PostgreSQL, Redis, Docker + Nginx, CI/CD, tests Pytest – bonnes pratiques appliquées au monde de l'IA.
- ▷ Déployé et utilisé par de vrais clients : **bichettethomas.site**.